

Informe del Proyecto Final

Clasificación de imágenes Fashion-MNIST con Machine Learning clásico

Fecha de entrega: 24/05/2026

Integrantes:

- Santiago Arango
- Jhon Rios
- Jhon Deiby Mejias

Resumen ejecutivo:


Este informe explica paso a paso el desarrollo de un sistema completo de clasificación de imágenes sin deep learning. El flujo incluye comprensión del problema, análisis exploratorio, preprocesamiento, extracción manual de características, construcción del dataset tabular, entrenamiento de nueve modelos clásicos, validación cruzada, PCA, pipelines y opción de rechazo.

1. Comprension del problema y del dataset


1. Problema de clasificación: predecir la clase de una imagen de 28x28 pixeles en escala de grises.
2. Tipo de problema: multiclase supervisado.
3. Numero de clases: 5 clases seleccionadas del dataset original de 10.
4. Interpretacion visual: T-shirt/top y Shirt son similares; Trouser y Bag se distinguen mejor; Dress ocupa una forma intermedia.
5. Dificultades visuales: baja resolucion, similitud entre clases, variabilidad interna, fondo negro uniforme y formas parcialmente ocluidas en algunas prendas.

Evidencia visual del problema

La distribución es balanceada y las clases visualmente mas confusas son T-shirt/top y Shirt.



Muestras representativas



2. EDA de alta profundidad

El EDA confirma que el dataset esta balanceado: las 5 clases tienen aproximadamente la misma cantidad de muestras.

Cada imagen es monocromatica, de tamaño fijo 28x28, con un solo canal.


Se analizaron conteos, porcentajes, muestras representativas, histogramas de intensidad, brillo, contraste, textura, bordes, similitud entre clases y outliers visuales.

La distribución por clase es casi uniforme, por lo que no fue necesario balanceo adicional.


EDA visual

La intensidad confirma un fondo negro dominante; el contraste y el brillo ayudan a distinguir clases.

Histogramas de intensidad




Contraste por clase




Brillo, textura y bordes

Estas vistas muestran que las prendas difieren mas por forma y textura que por color.


Brillo



Textura




Bordes



Clases parecidas y outliers


La matriz de similitud confirma la cercanía entre T-shirt/top y Shirt.

Similitud entre clases



Outliers visuales

Detección de Posibles Outliers Visuales



3. Preprocesamiento digital de imagenes


Se justifico un flujo de preprocesamiento simple porque Fashion-MNIST ya viene alineado, en escala de grises y con fondo negro.

Pasos aplicados: normalizacion de intensidades, reshape a 28x28 cuando fue necesario, segmentacion Otsu para comparar imagen original vs segmentada y extraccion de region del objeto sobre un fondo simple.

La comparacion original vs segmentada mostro que Otsu separa bien el objeto en la mayoria de casos, aunque no siempre mejora de forma clara todas las clases.

Comparacion de preprocesamiento

Otsu separa razonablemente el objeto del fondo en la mayoría de casos.



4. Extraccion de características visuales

Se construyeron 103 características documentadas.

Familia de intensidad: 45 variables, incluyendo estadísticas, histogramas y medias por zonas 4x4.

Familia de forma/bordes: 18 variables, con área, perímetro, bounding box, relación alto/ancho, centroide, momentos de Hu y densidad de bordes.

Familia de textura: 22 variables, incluyendo LBP, GLCM y estadísticos tipo HOG.

El dataframe final almacena una fila por imagen, una columna por característica y una columna objetivo y.

También se revisó correlación para detectar redundancia y relaciones fuertes entre variables.


Documentacion resumida de variables

Ejemplo de las variables documentadas para el dataset tabular final.

Nombre	Familia	Descripción
intensity_mean	Intensidad	Media de intensidad de todos los píxeles
intensity_std	Intensidad	Desviación estándar de intensidad
intensity_min	Intensidad	Valor mínimo de intensidad
intensity_max	Intensidad	Valor máximo de intensidad
intensity_median	Intensidad	Mediana de intensidad
intensity_p25	Intensidad	Percentil 25 de intensidad
intensity_p75	Intensidad	Percentil 75 de intensidad
intensity_range	Intensidad	Rango de intensidad (max - min)
brightness	Intensidad	Brillo promedio de la imagen
contrast	Intensidad	Contraste (desviación estándar de intensidad)
entropy	Intensidad	Entropía de Shannon de la distribución de intensidad
dark_pixel_ratio	Intensidad	Proporción de píxeles oscuros (< 0.3)
bright_pixel_ratio	Intensidad	Proporción de píxeles claros (> 0.7)
histogram_bin_0	Intensidad	Bin 0 del histograma de intensidad (16 bins)
histogram_bin_1	Intensidad	Bin 1 del histograma de intensidad (16 bins)
histogram_bin_2	Intensidad	Bin 2 del histograma de intensidad (16 bins)
histogram_bin_3	Intensidad	Bin 3 del histograma de intensidad (16 bins)
histogram_bin_4	Intensidad	Bin 4 del histograma de intensidad (16 bins)

Correlacion entre caracteristicas

Sirve para detectar variables redundantes o muy relacionadas.



5. Construcción del dataset tabular final

Cada fila del dataframe representa una imagen.
Cada columna representa una característica extraída.
Se agregó la columna objetivo y y metadatos de apoyo.
El dataset se guardó en CSV para reutilización posterior.

6. Division train/test

Se uso `train_test_split` con estratificacion y semilla fija para garantizar reproducibilidad.

La justificacion del porcentaje es mantener el esquema original de Fashion-MNIST para comparabilidad con benchmarks, ademas de una division controlada adicional para verificacion interna.

La estratificacion conserva la proporcion de clases en train y test, evitando folds desbalanceados.

7. Modelos obligatorios

Se entrenaron los 9 modelos obligatorios: Perceptron, Adaline aproximado con SGD, Regresion Logistica, SVM lineal, SVM polinomico, SVM RBF, KNN, Arbol de Decision y Bosque Aleatorio. El mejor modelo del experimento fue SVM RBF (optimizado) con F1 macro de 0.8887 y accuracy de 0.8886.


La comparacion muestra que los modelos basados en margen y ensambles superan a los modelos lineales mas simples, mientras que Adaline es el mas debil en este conjunto de características.

Comparacion de modelos

El más fuerte por modelo.

SVM RBF y Random Forest aparecen como los modelos más fuertes.

Comparación de Modelos: F1 Macro



Top 5 modelos finales

Resumen consolidado de los mejores modelos segun F1 macro.

Modelo	Accuracy	F1_macro	F1_weighted	Precision_macro	Recall_macro	Tiempo_train (s)
SVM RBF (optimizado)	0.8886	0.8887	0.8887	0.8891	0.8886	25.831
SVM RBF	0.8756	0.8756	0.8756	0.8769	0.8756	7.09
Random Forest	0.8754	0.8752	0.8752	0.8762	0.8754	0.688
Random Forest (optimizado)	0.8754	0.8752	0.8752	0.8762	0.8754	0.848
SVM RBF	0.8686	0.8685	0.8685	0.87	0.8686	52.635

8. PCA y reduccion de dimensionalidad

PCA se uso para estudiar la reduccion de dimensionalidad y su efecto sobre el desempeno. De acuerdo con la curva de varianza acumulada, aproximadamente 26 componentes explican el 90 %, 40 componentes el 95 % y 62 componentes el 99 %.


PC1 y PC2 explican una fraccion importante de la varianza, pero la separacion visual sigue siendo parcial, lo que confirma que PCA comprime informacion sin resolver por completo la confusiones entre clases parecidas.

En general, PCA ayudo a algunos modelos sensibles a dimensionalidad, pero no siempre mejoro el rendimiento de todos.


PCA: varianza y proyeccion

La separacion mejora parcialmente, pero no resuelve por completo la confusiones entre clases.

Varianza acumulada



PC1 vs PC2




PCA en 3D

La vista 3D ayuda a entender la estructura global del espacio de características.

PC1 vs PC2 vs PC3

Visualización PCA 3D: PC1 vs PC2 vs PC3



9. Validacion cruzada e hiperparametros

Se aplico StratifiedKFold y validacion cruzada para estimar la estabilidad del modelo. Ademas, se usaron GridSearchCV o una busqueda equivalente de hiperparametros para los modelos mas prometedores.

La comparacion entre validacion cruzada y test final permite medir la varianza del modelo y detectar sobreajuste.

10. Uso de Pipeline

Se implementaron dos pipelines: uno sin PCA y otro con PCA.

Cada pipeline organiza escalamiento, posible reduccion de dimensionalidad y clasificacion en una sola secuencia reproducible.

Esto evita fuga de informacion y mantiene el flujo correcto de entrenamiento y evaluacion.

11. Evaluacion final


La evaluacion final incluyo matriz de confusion, accuracy, precision, recall, F1-score, analisis por clase y ejemplos de errores.

Las clases mas confundidas fueron T-shirt/top y Shirt, algo coherente con su similitud visual.

Las imagenes mal clasificadas muestran prendas ambiguas, de bajo contraste o con siluetas poco marcadas.

Las confusiones dominantes aparecen entre T-shirt/top y Shirt.
Matriz de confusion final

Matriz de confusion final



Predicciones correctas




Predicciones incorrectas



Comparacion completa de matrices de confusión de todos los modelos

Permite comparar el comportamiento por clase de cada clasificador.

Matrices de Confusión - Todos los Modelos



12. Opcion de rechazo

Se aplico la opcion de rechazo al mejor modelo para abstenerse de clasificar cuando la confianza era baja.


El umbral 0.7 logro una accuracy sobre muestras aceptadas de 0.9486 con una tasa de rechazo de 15.1%.

El mayor beneficio aparece al aceptar solo predicciones mas seguras; a la vez, el costo es rechazar mas muestras. La clase mas rechazada cambia entre Shirt y T-shirt/top segun el umbral.

Con umbral 0.9, la accuracy aceptada sube a 0.9813, pero el rechazo aumenta a 33.7%.


Analisis de opcion de rechazo

El rechazo mejora la confianza del sistema al costo de abstenerse en una fraccion de muestras.



Muestras rechazadas

Muestras Rechazadas (umbral = 0.7)



13. Conclusiones

El proyecto cumple con el flujo completo pedido en la asignatura: EDA, preprocesamiento, extracción manual de características, dataset tabular, modelos clásicos, PCA, validación cruzada, pipelines, evaluación final y opción de rechazo.

La conclusión técnica principal es que las características de forma y textura aportan más discriminación que las variables simples de intensidad, especialmente para separar prendas con siluetas distintas.

Las clases más difíciles siguen siendo T-shirt/top y Shirt, por lo que cualquier mejora futura debería enfocarse en descriptores más robustos o en representaciones más expresivas.